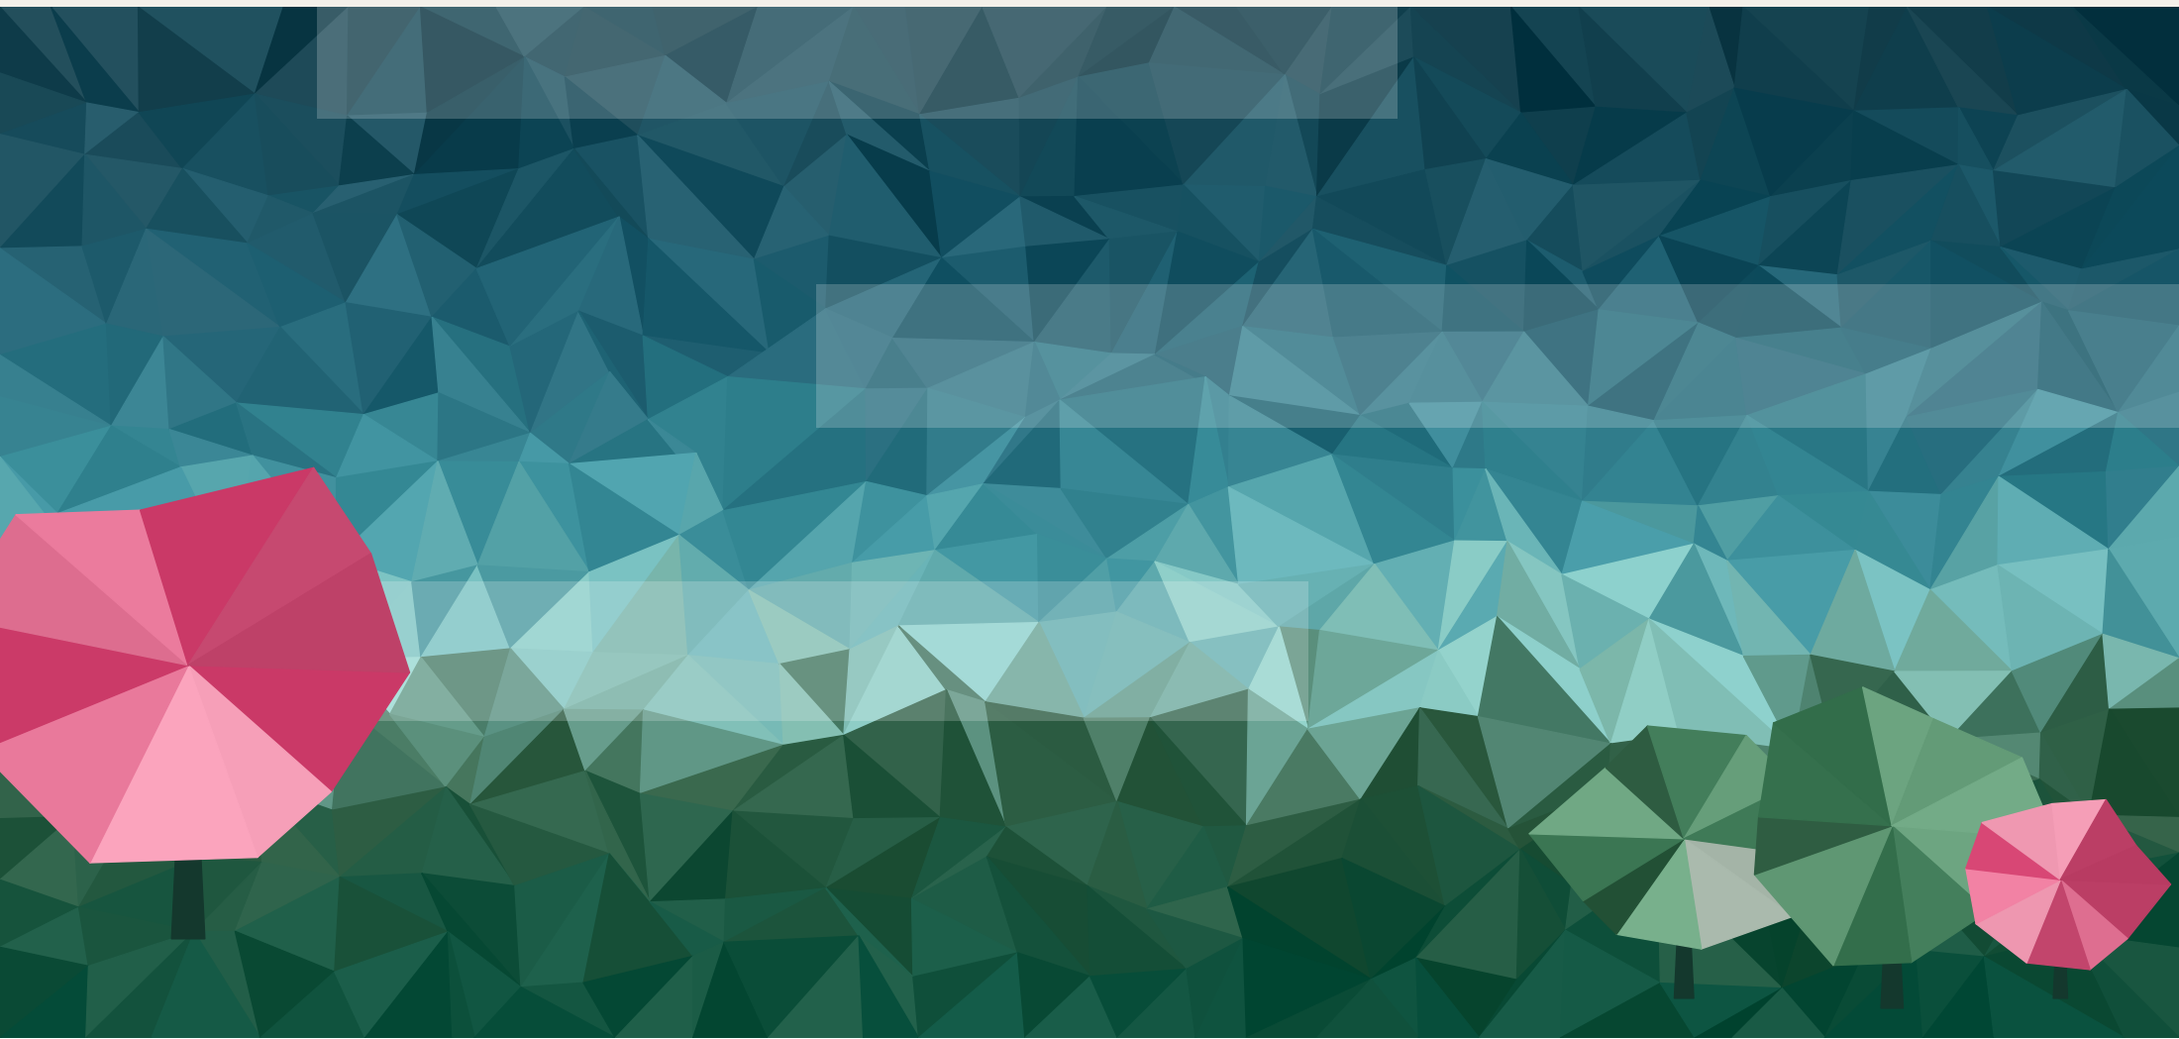
RELATÓRIO DE SRE · 2026

OBSERVABILIDADE, CUSTO E ROI

EcoCiente

EcoCiente IA (ia-eko) 01/11/2026 deepseek-flash · sem thinking US$ 1 = R$ 5,4325 medições no código 583a8c9



CINCO PERGUNTAS DE SRE

Quanto custa, quão rápido responde, quanto erra, quanto retorna e quanto custa cada problema resolvido.

COMO LER ESTE RELATÓRIO

Cada número traz uma etiqueta de origem. Nenhum valor foi inventado: o que depende de tráfego real com a DeepSeek ou de benefício ainda não foi medido e aparece como tal. A infraestrutura é estimada a partir do Terraform da equipe.

MEDIDO saiu de uma execução do sistema, com o método descrito na página 15.

ESTIMADO calculado por fórmula a partir de premissas declaradas.

PREMISSA valor assumido, sem medição por trás.

A MEDIR ainda não existe número; o relatório indica como obtê-lo.



O RESUMO EM CINCO NÚMEROS

Cada cartão responde a um requisito do trabalho. As páginas seguintes mostram como chegamos a cada um.

CUSTO ESTIMADO

R$ 1,35

por semana · 100 usuários

Com 1.000 usuários: **R$ 13,51**. Caso esperado, só API. Infraestrutura na AWS: **R$ 26,09** por semana.

ESTIMADO

TEMPO DE RESPOSTA

155 ms

p95 · 10 simultâneas

Com o LLM simulado: é o piso do sistema. Uma por vez: 20 ms. Com a DeepSeek: a medir.

MEDIDO | A MEDIR

ÍNDICE DE ERROS

0 de 400

falhas 5xx no teste

Com o LLM simulado, que nunca falha. A taxa em produção depende da DeepSeek: a medir.

MEDIDO | A MEDIR

CUSTO POR RESOLUÇÃO

R$ 0,0032

por resolução · caso esperado

Só API, com 85% de resolução assumida. Infraestrutura fora da conta.

ESTIMADO

CUSTO/RETORNO (ROI)

+254%

por condomínio · com infra

Benefício: tempo do síndico liberado, R$ 83,58 por mês. Com síndico morador, +447%; com profissional, +27%.

ESTIMADO | PREMISSA

O QUE ESTE RELATÓRIO NÃO AFIRMA

Três limites que valem para todos os números.

- Que a resposta com a DeepSeek terá a latência medida aqui: o LLM foi simulado, então os tempos são do sistema sem o modelo.
- Que a taxa de resolução é de 100%: o juiz simulado aprova tudo. A taxa das contas, 85%, é uma premissa.
- Que o benefício é exato: ele depende de quanto do tempo do síndico vai em dúvidas, que não tem fonte. A infraestrutura vem do Terraform e do preço de lista da AWS.

Custo de API por semana

ESTIMADO

100 usuários custam R$ 1,35 por semana e 1.000 usuários, R$ 13,51, no caso esperado.

Caso esperado · só custo de API

R$ 1,35 /semana

100 usuários · 500 solicitações

R$ 13,51 /semana

1.000 usuários · 5.000 solicitações

O custo de uma resposta vem dos tokens que ela consome e dos preços do **deepseek-flash sem thinking**, que mudam com o horário (pico ou fora do pico) e com o uso de cache.

Como ainda não há tráfego real com a DeepSeek, o tráfego no pico e o cache foram tratados como faixa, do melhor caso ao pior. Mil usuários custam exatamente 10 vezes mais em API.

O QUE ISSO SIGNIFICA

Nesta escala a API custa centavos por semana. O que pesa de verdade é a infraestrutura: R$ 26,09 por semana na AWS (página 11), por causa dos 2,5 GB de memória que a IA reserva para o modelo de embeddings.

	100 usuários			1.000 usuários		
	Melhor	Caso esperado	Pior	Melhor	Caso esperado	Pior
Solicitações	500	500	500	5.000	5.000	5.000
Custo por solicitação	R$ 0,0015	R$ 0,0027	R$ 0,0064	R$ 0,0015	R$ 0,0027	R$ 0,0064
Custo de API	R$ 0,735	R$ 1,35	R$ 3,19	R$ 7,35	R$ 13,51	R$ 31,94
Resoluções	425	425	425	4.250	4.250	4.250

Melhor caso: fora do pico, 90% de cache. Caso esperado: 20,8% no pico, 50% de cache (tráfego uniforme na semana: 35 h de 168 h no pico). Pior caso: tudo no pico, sem cache.

Como o custo é calculado

Preço por token da DeepSeek, que muda com o horário e com o cache.

Preços usados (US$ por 1M de tokens)

	Pico	Fora do pico
Entrada, cache hit	0,006	0,003
Entrada, cache miss	0,30	0,15
Saída	1,20	0,60

Pico: 01h–04h e 06h–10h UTC (22h–01h e 03h–07h em Brasília), de segunda a sexta. A DeepSeek pode reajustar os preços.

Premissas PREMISSA

Solicitações por usuário por semana	5
Tokens de entrada por resposta	2.400
Tokens de saída por resposta	380
Respostas resolvidas	85%
Infraestrutura por semana	R$ 26,09

O QUE ISSO SIGNIFICA

O preço é previsível: depende dos tokens e de quanto do prompt cai no cache. O que ainda pode mexer no custo é o tamanho real das respostas, que será medido com a DeepSeek.

FÓRMULAS

```
preço(campo)          = fatia_pico × pico(campo) + (1 - fatia_pico) × fora_do_pico(campo)
custo da resposta US$ = [entrada × (cache × preço(hit) + (1 - cache) × preço(miss))
                         + saída × preço(saída)] ÷ 1.000.000
custo por solicitação = custo da resposta × cotação
custo de API semanal  = usuários × solicitações por usuário × custo por solicitação
```

Fonte dos preços: api-docs.deepseek.com/quick_start/pricing, consultada em 01/11/2026. Cotação: Frankfurter (api.frankfurter.dev), US$ 1 = R$ 5,4325 em 30/10/2026. As premissas são as mesmas do painel de controle e podem ser editadas lá.

Tempo total de resposta

MEDIDO

Sem o modelo, o sistema responde em 14 ms (mediana, uma requisição por vez).

p95 do tempo total · LLM simulado

20 ms

uma requisição por vez · 200 requisições

155 ms

10 simultâneas · 200 requisições

As medições vieram do sistema real rodando com o **LLM simulado** (`LLM_PROVIDER=mock`): o modelo responde na hora.

Elas mostram o custo de tempo do próprio sistema: guardrails, memória, roteamento, juiz e serialização. O tempo esperando a DeepSeek **não** está incluído A MEDIR.

O QUE ISSO SIGNIFICA

Estes tempos são um piso. O usuário só vai sentir a latência real quando o modelo da DeepSeek entrar na conta.

	Média	Mediana	p95	p99	Erros	Vazão
Uma por vez	15,0 ms	14,2 ms	20,1 ms	28,0 ms	0,00%	66,5 req/s
10 simultâneas	121,3 ms	118,8 ms	154,7 ms	166,0 ms	0,00%	81,6 req/s

Medido pelo cliente, com `scripts/benchmark_api.py`. Máquina de desenvolvimento (Windows, Python 3.14), sem rede externa, sem bancos, API e cliente no mesmo computador. Resultado de uma execução; não é capacidade de produção.

Latência entre agentes

MEDIDO

O especialista educacional concentra 96% do tempo das etapas do grafo.

O roteamento caiu sempre nele (400 de 400 decisões); as outras rotas não foram exercitadas.

Etapa	Chamadas	Média	p50	p95	Escala do p95 (0 a 39 ms)
Guardrail de entrada	400	< 0,1 ms	< 5 ms	< 5 ms	
Memória	400	< 0,1 ms	< 5 ms	< 5 ms	
Verificar compactação	400	< 0,1 ms	< 5 ms	< 5 ms	
Orquestrador	400	0,1 ms	< 5 ms	< 5 ms	
Educacional	400	12 ms	5,3 ms	39 ms	
Juiz de saída	400	0,1 ms	< 5 ms	< 5 ms	
Guardrail de saída	400	0,1 ms	< 5 ms	< 5 ms	
Entre as etapas	–	50 ms	–	–	fora das etapas do grafo
Total (servidor)	400	63 ms	50 ms	231 ms	

O QUE ISSO SIGNIFICA

Das 63 ms de média no servidor, só 12 ms estão nas etapas; o resto fica fora delas e as métricas atuais não o detalham.

O QUE MUDA COM A DEEPSEEK A MEDIR

No caminho padrão o grafo encadeia o orquestrador, o especialista e o juiz de saída, e cada um faz ao menos uma chamada ao LLM; se o juiz reprova, entram a correção e um novo juízo. FAQ via Qdrant e coletas não passam por juiz LLM.

O tempo total com a DeepSeek será o do sistema somado às chamadas ao modelo, o gargalo esperado.

COMO MEDIR

Rodar o benchmark com `LLM_PROVIDER=deepseek` e a chave no ambiente, e ler a latência por etapa e por chamada em `ecociente_agent_duration_seconds` e `ecociente_llm_duration_seconds`.

O projeto já alerta se o p95 do `/chat` passar de 15 s por 10 minutos (`alerts.yml`).

p50 e p95 são interpolações dos buckets do histograma (o menor vai até 5 ms): valem como ordem de grandeza. A média é exata.

Índice de erros MEDIDO

0 falhas em 400 requisições no teste com o LLM simulado.

Falhas 5xx · LLM simulado

0 de 400

0,00% das requisições

MEDIDO A MEDIR

Definição: índice de erros = requisições com falha de servidor (HTTP 5xx ou exceção) ÷ requisições totais.

Respostas 4xx (cliente), bloqueios do guardrail e recusas por limite de uso não entram: aparecem em contadores próprios.

O QUE ISSO SIGNIFICA

Zero erros prova pouco: o modelo simulado nunca falha, atrasa ou devolve saída inválida. A taxa real depende da DeepSeek.

Sinal	Resultado do teste	Métrica
Falhas 5xx	0 de 400 (0,00%)	ecociente_http_request_errors_total
Respostas reprovadas pelo juiz	0 de 400	ecociente_judge_decisions_total
Entradas barradas pelo guardrail	0	ecociente_guardrail_blocked_total
Recusadas por limite de uso	0	ecociente_quota_rejected_total

A carga foi pequena (400 requisições) e sem timeouts nem limites de uso da DeepSeek. Para acompanhar em produção: `sum(rate(ecociente_http_request_errors_total[5m])) / sum(rate(ecociente_http_requests_total[5m]))`.

Custo por resolução

ESTIMADO

Cada resolução custa R$ 0,0032 de API no caso esperado.

Por resolução · caso esperado · só API

R$ 0,0032

Faixa: R$ 0,0017 (melhor caso) a R$ 0,0075 (pior caso)

ESTIMADO PREMISSA

Definição: uma solicitação é *resolvida* quando a resposta final é aprovada pelo juiz de saída. Bloqueios do guardrail e respostas reprovadas após as correções não contam.

`custo por resolução = custo total ÷ resoluções`. As bloqueadas e reprovadas entram no custo, então quanto menos resolve, mais cada resolução custa.

O QUE ISSO SIGNIFICA

O custo por resolução é a métrica que une custo e qualidade: melhorar a taxa de aprovação do juiz reduz o custo de cada problema resolvido.

	100 usuários			1.000 usuários		
	Melhor	Caso esperado	Pior	Melhor	Caso esperado	Pior
Custo de API por resolução	R$ 0,0017	R$ 0,0032	R$ 0,0075	R$ 0,0017	R$ 0,0032	R$ 0,0075

Com 85% de resolução assumida. Não inclui a infraestrutura (página 11): somando R$ 26,09 por semana, o custo por resolução vai a R$ 0,065 com 100 usuários e R$ 0,0093 com 1.000.

Custo/retorno (ROI)

ESTIMADO

Valendo o tempo do síndico, o ROI é de +132% com 1.000 usuários e de −67% com 100.

Ponto de equilíbrio · caso esperado · só API

R$ 0,0032

benefício mínimo por resolução para o ROI deixar de ser negativo

ESTIMADO PREMISSA

Fórmula:

```
ROI = (benefício - custo total)
      ÷ custo total
benefício = resoluções
          × benefício por resolução
```

Benefício estimado na página 14, pelo tempo do síndico: **R$ 0,022** por resolução. Com 100 usuários a infra fixa pesa mais que o benefício; com 1.000, ela se dilui.

O QUE ISSO SIGNIFICA

O benefício estimado vem de premissas. A tabela mostra o ROI só com API para outros valores de benefício.

Benefício por resolução (hipótese)	R$ 0,05	R$ 0,10	R$ 0,25	R$ 0,50	R$ 1,00
ROI com 100 usuários	+1.473%	+3.046%	+7.765%	+15.630%	+31.360%
ROI com 1.000 usuários	+1.473%	+3.046%	+7.765%	+15.630%	+31.360%

Os valores do cabeçalho são hipóteses de leitura, não estimativas do grupo. Caso esperado, só custo de API. Os percentuais são altos porque o custo de API por resolução é de frações de centavo; com a infraestrutura da página 11 eles caem bastante, sobretudo com 100 usuários, porque a infra é fixa.

Infraestrutura na AWS

ESTIMADO

A parte da IA na máquina da AWS custa R$ 26,09 por semana, com 100 ou com 1.000 usuários.

Parcela da IA · preço de lista

R$ 26,09 /semana

R$ 113,38 por mês · 31,25% da máquina

ESTIMADO PREMISSA

O Terraform da equipe (`devops-infra-ecociente`) sobe **uma EC2 t3.large com k3s** em us-east-1, com 30 GB de disco gp3 e um IP elástico. A máquina é dividida com as APIs Java.

A IA fica com a fatia da memória que reserva: 2.560 MiB de 8.192 MiB. Os bancos (MongoDB Atlas, Redis Cloud, Neo4j Aura e Qdrant Cloud) ficam fora da AWS e entram aqui no plano gratuito.

O QUE ISSO SIGNIFICA

A infra é custo fixo. Mil usuários fazem 5.000 perguntas por semana: mesmo concentradas em poucas horas, é menos de uma por vez, e a mesma réplica atende os dois cenários.

Item	Conta	Por mês
EC2 t3.large (2 vCPU, 8 GiB)	730 h × US$ 0,0832	US$ 60,74
Disco EBS gp3, 30 GB	30 GB × US$ 0,08	US$ 2,40
IPv4 público (Elastic IP)	730 h × US$ 0,005	US$ 3,65
Máquina inteira		US$ 66,79
Parcela da IA	× 31,25%	US$ 20,87 = R$ 113,38

Preço de lista sob demanda; no AWS Academy a conta é paga com créditos. Mês de 730 h; semana = mês ÷ 4,345. Nos planos pagos de entrada dos bancos (MongoDB Atlas Flex, US$ 8,00; Redis Cloud Essentials 250 MB, US$ 5,00; Neo4j AuraDB Professional 1 GB, US$ 65,00), somam-se US$ 78,00 por mês, ou R$ 97,52 por semana. A IA pode chegar a 3,5 GB dos 8 GB da máquina.

Condomínio residencial

ESTIMADO

A IA consome 4,1% do que um condomínio médio paga, no caso esperado.

Condomínio médio · por mês

R$ 300 /mês

receita do plano · 75 apartamentos × R$ 4,00

R$ 12,28 /mês

custo de API · 209 moradores

Condomínio médio: 75 apartamentos (média da cidade de São Paulo, Lello 2025) × 2,79 moradores por domicílio (IBGE, Censo 2022) = **209 moradores**.

Plano Empresarial Residencial: R$ 4,00 por apartamento por mês. Premissa: todos os moradores usam o chat 5 vezes por semana, o que é um teto.

O QUE ISSO SIGNIFICA

Receita e custo crescem juntos com o número de apartamentos, então a proporção vale de 58 a 118 apartamentos. A infra da IA (R$ 113,38 por mês) cabe na receita de um único condomínio.

	Melhor caso	Caso esperado	Pior caso
Solicitações por mês	4.546	4.546	4.546
Custo de API por mês	R$ 6,68	R$ 12,28	R$ 29,04
Por apartamento	R$ 0,089	R$ 0,164	R$ 0,387
Parte da receita do plano	2,2%	4,1%	9,7%

Melhor caso: fora do pico, 90% de cache. Caso esperado: 20,8% no pico, 50% de cache. Pior caso: tudo no pico, sem cache. Com 30% dos moradores usando, os custos de API caem para 30%. A infra fixa equivale a 38% da receita de um condomínio, ou 3,8% com 10 condomínios. A receita paga o produto inteiro, não só a IA.

Condomínio industrial

ESTIMADO

A IA consome 0,01% do que um condomínio logístico médio paga, no caso esperado.

Condomínio médio · por mês

R$ 20.651 /mês

receita do plano · 41.302 m² × R$ 0,50

R$ 2,94 /mês

custo de API · 50 usuários

Condomínio médio: 42,5 milhões de m² de área locável em 1.029 condomínios logísticos prontos no Brasil (Buildings, 3º tri. 2025) = **41.302 m²** por condomínio.

Plano Industrial: R$ 0,50 por m² por mês. Não há fonte para o número de usuários: a premissa é de 50 pessoas das empresas ocupantes usando o chat 5 vezes por semana.

O QUE ISSO SIGNIFICA

No industrial o preço é por área, não por pessoa. A IA é desprezível frente à receita, mesmo com dez vezes mais usuários.

	Melhor caso	Caso esperado	Pior caso
Solicitações por mês	1.086	1.086	1.086
Custo de API por mês	R$ 1,60	R$ 2,94	R$ 6,94
Parte da receita do plano	0,008%	0,014%	0,034%
Parte da receita, 500 usuários	0,08%	0,14%	0,34%

A área média mistura todas as classes de galpão; na classe A ela é de 53.920 m² (625 condomínios). A infra fixa da IA (R$ 113,38 por mês) equivale a 0,55% da receita de um condomínio.

Tempo do síndico ESTIMADO

O chatbot devolve ao síndico 4,9 h por mês por condomínio, ou R$ 83,58, na média.

Benefício por condomínio · por mês

R$ 129,29 /mês

síndico morador · 7,5 h liberadas

R$ 29,91 /mês

síndico profissional · 1,7 h liberadas

Hora do síndico: R$ 3.214,86 por mês ÷ (43 h × 4,345 semanas) = **R$ 17,21** (Salário.com.br, CAGED). **Dedicação** (Datafolha): o morador dá 19 h por semana a 103 unidades e o profissional, 32 h a 750. Para 75 apartamentos: 13,8 h e 3,2 h por semana.

PREMISSA 25% desse tempo vai em responder dúvidas, e o chatbot absorve 50% delas.

O QUE ISSO SIGNIFICA

Com síndico morador a IA se paga com folga. O profissional passa tão pouco tempo em cada condomínio que o benefício fica perto do custo.

	Morador	Profissional	Média (46% prof.)
Horas por semana no condomínio	13,8 h	3,2 h	8,9 h
Horas liberadas por mês	7,5 h	1,7 h	4,9 h
Benefício por mês	R$ 129,29	R$ 29,91	R$ 83,58
ROI por condomínio	+447%	+27%	+254%
Benefício por resolução	R$ 0,033	R$ 0,0077	R$ 0,022

Custo da IA por condomínio: R$ 12,28 de API (caso esperado, página 12) + infra dividida por 10 condomínios = R$ 23,62 por mês. 3.864 resoluções por mês. Sem encargos trabalhistas, então a hora real custa mais. A média por resolução, R$ 0,022, é a que está no `.env`.

MÉTODO E LIMITAÇÕES

Tudo o que foi medido veio de uma máquina e de uma execução.

COMO AS MEDIÇÕES FORAM FEITAS

1. API do ia-eko iniciada localmente com `LLM_PROVIDER=mock`, `EMBEDDING_PROVIDER=mock` e `STORAGE_MODE=memory` (sem bancos, sem rede externa).
2. Duas execuções de `scripts/benchmark_api.py`, de 200 requisições cada, com concorrência 1 e 10; saídas em `relatorio/dados/`.
3. Leitura do `/metrics` e do `/api/v1/costs` ao final, com os mesmos histogramas que o painel usa. Percentis por interpolação linear nos buckets.
4. Custos pelas funções `simular` e `faixaPorSolicitacaoBrl` do painel (`dashboard/src/data/simular.ts`), testadas: relatório e painel mostram os mesmos números.

Para regerar: `node relatorio/gerar.mjs` a partir da raiz, com `npm install` feito em `dashboard/`.

LIMITAÇÕES

- **LLM simulado.** Latência, erros e resolução descrevem o sistema sem o modelo: um piso, não a experiência do usuário.
- **Rota única.** Só o especialista educacional foi exercitado; FAQ, analytics, coletas e grafo têm custos de tempo diferentes.
- **Uma máquina, uma execução.** Sem repetição nem carga sustentada.
- **Resolução e tokens são premissas.** O juiz simulado aprova tudo e o LLM simulado não reporta tokens.
- **Infraestrutura e benefício em zero.** Sem eles não há custo total completo nem ROI único.
- **Preços e cotação mudam.** Valem na data da consulta.
- **Código mudou depois da medição.** O thinking da DeepSeek só passou a ser desligado no código em 01/11/2026, e a base de conhecimento passou para o Qdrant. Os tempos medidos são anteriores a isso.

FONTES

De onde vem cada número externo.

- IBGE, Censo Demográfico 2022: média de 2,79 moradores por domicílio ocupado (divulgado em 28/06/2023).
  `agenciadenoticias.ibge.gov.br/agencia-noticias/2012-agencia-noticias/noticias/37238-pais-tem-90-milhoes-de-domicilios-34-a-mais-que-em-2010`
- Lello, Mapa dos Condomínios 2025, via Jovem Pan (27/04/2025): 31,1 mil condomínios na cidade de São Paulo, 75 apartamentos em média, de 58 (zona sul) a 118 (zona norte).
  `jovempan.com.br/noticias/brasil/zona-sul-concentra-maior-numero-de-condominios-em-sao-paulo-aponta-levantamento.html`
- Buildings (06/10/2025): 1.029 condomínios logísticos prontos e 42,5 milhões de m² de área locável no Brasil; classe A, 33,7 milhões de m² em 625.
  `revista.buildings.com.br/brasil-tem-57-milhoes-de-m²-em-construcao-logistica`
- Salário.com.br (CAGED, atualizado em 08/10/2026): síndico de edifícios (CBO 510110), média de R$ 3.214,86 por mês para 43 h semanais.
  `salario.com.br/profissao/sindico-edificios-cbo-510110`
- Datafolha para o Grupo Superlógica, Perfil do Síndico Brasileiro (via Revista Meu Condomínio, 04/12/2025): 46% profissionais; profissional, 8 condomínios, 750 unidades, 32 h por semana; morador, 103 unidades, 19 h por semana.
  `revistameucondominio.com.br/pesquisa-aponta-que-46-dos-sindicos-no-brasil-ja-atuam-de-forma-profissional`
- EcoCiente, tabela de planos: Empresarial Residencial R$ 4,00 por unidade por mês; Industrial R$ 0,50 por m² por mês.
- DeepSeek, preços do deepseek-flash (consultados em 01/11/2026).
  `api-docs.deepseek.com/quick_start/pricing`
- Frankfurter, cotação de 30/10/2026: US$ 1 = R$ 5,4325.
  `api.frankfurter.dev/v1/latest?base=USD&symbols=BRL`
- Terraform da equipe de infraestrutura: EC2 t3.large, 30 GB gp3, Elastic IP, us-east-1.
  `github.com/EcoCiente-Instituto-J-F/devops-infra-ecociente (terraform/aws)`
- AWS EC2 sob demanda: t3.large em us-east-1, US$ 0,0832 por hora (conferido em aws-pricing.com, 31/10/2026).
  `aws.amazon.com/ec2/pricing/on-demand`
- AWS EBS: gp3 em us-east-1, US$ 0,08 por GB-mês.
  `aws.amazon.com/ebs/pricing`
- AWS VPC: IPv4 público, inclusive Elastic IP, US$ 0,005 por hora.
  `aws.amazon.com/vpc/pricing`
- MongoDB Atlas Flex: de US$ 8 a US$ 30 por mês.
  `mongodb.com/docs/atlas/billing/atlas-flex-costs`
- Redis Cloud Essentials 250 MB: US$ 5 por mês (valor de marketplace; confirmar na calculadora).
  `redis.io/pricing`
- Neo4j AuraDB Professional: US$ 65 por GB por mês, mínimo de 1 GB.
  `neo4j.com/pricing`
- Qdrant Cloud: plano gratuito com 1 GB de RAM e 4 GB de disco; pago por uso.
  `qdrant.tech/pricing`